

João Rietra

AI Engineer · IA generativa, LLMs, RAG, agentes e avaliação de modelo

Recife, PE · (81) 99243-3485

joaorietra@gmail.com · jhlr.github.io · github.com/jhlr · linkedin.com/in/joaorietra

RESUMO

AI Engineer e Data Scientist com padrão inovador de avaliação de modelo em qualquer domínio. Testado na minha dissertação de mestrado e replicado em todo modelo que assino hoje. Meio calibração e generalização fora da distribuição de treino como critério de aceite. Desenho a arquitetura de dado que sustenta produção, do banco relacional ao vetorial. Avalio maturidade de projeto pela robustez do pipeline, não pela métrica em ambientes controlados.

PALAVRAS-CHAVE

Python · PyTorch · MLflow · Docker · AWS · Git · SQL · calibração de modelo (ECE) · avaliação fora-de-distribuição (OOD) · LGPD e dados sensíveis · IA generativa · LLMs · RAG · fluxos agênticos · tool-calling · Model Context Protocol (MCP) · engenharia de prompt · TypeScript · NestJS · React · PostgreSQL (pgvector) · Groq · FastAPI · Redis/BullMQ · CI/CD (GitHub Actions) · fine-tuning (LoRA) · mentoria e ensino técnico · liderança técnica de subprojeto · trabalho em time multidisciplinar · metodologias ágeis (Scrum/Kanban)

FORMAÇÃO

- **Mestrado Profissional em Engenharia de Software** — CESAR School, Recife · Out/2025 – defesa prevista para Nov/2026
- **Medicina** — FPS / IMIP, Recife · Concluído em 2022

EXPERIÊNCIA

AI Engineer — LetzGrow (School Innovation, CESAR School) · 2026 – atual

Plataforma de carreira assistida por IA: o candidato percorre uma trilha com o Mentor IA e recebe um PDI personalizado. Classificada na edição 2026.2, em dupla.

- **Mentor IA:** agente conversacional sobre LLM (Groq, Llama 3.3 70B) que conduz a jornada, interpreta respostas abertas e gera recomendações de trilha personalizadas.
- **Fluxos agênticos:** geração de PDI com decomposição em micro-tarefas adaptativas, em vez de template fixo.
- **RAG:** recomendações ancoradas no perfil do usuário e no domínio por busca semântica em pgvector.
- **Backend NestJS 11 + Prisma 5 sobre PostgreSQL 15**, API documentada em Swagger, autenticação JWT (access + refresh com rotation) e OAuth LinkedIn.
- **Ingestão assíncrona de perfil técnico via GitHub** com BullMQ + Redis, processada fora do request e com retry.
- **AWS CDK e CI/CD no GitHub Actions:** deploy automático no merge para `main`, com role OIDC e segredos em Secrets Manager; acesso condicional e trilha de auditoria alinhados à LGPD.

Lead técnico (dados e visão computacional) — MAPEN (School Innovation, CESAR School) · 2026 – atual

Sistema que localiza perdas de energia comparando energia distribuída e consumida, com redflags por região. Classificado na edição 2026.2.

- **Base de dados nacional** (séries horárias do ONS 2000→2026, consumo faturado por UF e malha do IBGE em DuckDB) e leitura automática de medidores por fine-tuning de TrOCR-small, com tracking em MLflow.

ML Engineer — Veritas (School Innovation, CESAR School) · 2025 – 2026

Deteção de deepfake.

- **Tríade da confiança:** score forense da CNN, heatmap Grad-CAM e leitura contextual por IA generativa (Gemini/GPT) na mesma API.

- **Backend FastAPI + SQLAlchemy** que carrega o modelo no lifespan e expõe endpoint de predição por upload de imagem.

Engenheiro de Software (Domínio Clínico + QA) — GasoGraph (Mestrado / CESAR) · 2025 – 2026

Sistema de apoio à decisão clínica (CDSS) na interpretação de gasometria arterial veterinária, com regras de consensos publicados.

- **Grafos de decisão clínica e motor de regras:** traduzi os consensos em fluxogramas e implementei a árvore de regras a partir deles.
- **QA orientado ao uso clínico:** testava cada versão como um médico usaria, conferindo se a ferramenta cumpria o propósito clínico.

Monitor — CESAR School · 2025 – 2026

- Monitorias em Programação (C), Estatística (R), Cálculo I, Programação Competitiva e Análise e Visualização de Dados.

Analista de Dados Médicos — J & L Consultoria Hospitalar · 2023 – 2024

Análise de dados clínicos e gerenciais para apoiar a governança hospitalar.

- **Desfechos clínicos:** medi reinternação, infecção hospitalar e complicações pós-operatórias, apontando falhas e apoiando o ajuste de protocolos.
- **Qualidade e gestão:** acompanhei os KPIs da ONA e da JCI e analisei ocupação de leitos, centro cirúrgico e custos, com dashboards em Streamlit.

PROJETOS

ragcode — servidor MCP próprio · github.com/jhlr/ragcode

Servidor Model Context Protocol (stdio) que expõe um LLM local (Ollama) como ferramentas, com índice semântico de código incremental por commit em SQLite.

Minnow — agente de coding no navegador do celular · github.com/jhlr/minnow

Agente inteiro no cliente: ferramentas permissionadas, IndexedDB, Python (Pyodide), git (isomorphic-git) e modelo on-device via WebAssembly com tool-calling; turn otimizado de 420 s para 176 s.

PRODUÇÕES ACADÊMICAS

1. *Reuso de Treino para Triagem Binária em Imagem Médica Multidomínio* (dissertação de mestrado, CESAR School, 2026): 4 origens de backbone sobre 5 domínios, com calibração ECE 0,045 vs. 0,219 do ImageNet.
2. *Generalização assimétrica em detectores de manipulação de imagens: do domínio de treino ao colapso em splicing manual* (SBTI 2026, submetido).
3. *Fine-tuning de decision forests na presença de drift: um blend bayesiano com vocabulário unificado* (SBTI 2026, submetido).
4. *EfficientNeXt: um mini-LLM autoregressivo derivado da arquitetura EfficientNet com geração e embedding unificados (GRIT) e steering de decoding sem modelo auxiliar.*
5. *Fiscalização automatizada de fotos de leitura de medidores de energia elétrica: um pipeline de OCR e caracterização do problema de validação de coerência* (SBTI 2026, submetido).

COMPETÊNCIAS

IA generativa: OpenAI, Anthropic, Groq, Gemini e Ollama · engenharia de prompt · RAG e busca vetorial · fluxos agênticos e tool-calling · Model Context Protocol (MCP) · fine-tuning com LoRA · avaliação de LLM (groundedness, alucinação)

Machine learning: PyTorch · scikit-learn · Hugging Face Transformers · OpenCV · OCR · Grad-CAM e explicabilidade · calibração (ECE) · avaliação OOD

Engenharia e dados: Python (FastAPI) · TypeScript (NestJS, React) · PostgreSQL e SQL · Redis/BullMQ · JWT/OAuth · Docker · AWS (CDK) · GitHub Actions · MLflow · DuckDB · LGPD e dados sensíveis

Idiomas: Português (nativo) · Inglês (nativo) · Espanhol (básico) · Francês (básico)