

João Rietra

AI Engineer / Data Scientist · avaliação de modelo, arquitetura de dados e IA aplicada

Recife, PE · (81) 99243-3485

joaorietra@gmail.com · jhlr.github.io · github.com/jhlr · linkedin.com/in/joaorietra

RESUMO

AI Engineer e Data Scientist com formação médica, criador de um padrão de avaliação de modelo fora do domínio projetado, que aplico em cada time que integro. Testado na dissertação de mestrado e replicado em todo modelo que assino. Avalio calibração e generalização fora da distribuição de treino como critério de aceite. Desenho a arquitetura de dado que sustenta produção, do banco relacional ao vetorial. Tenho sistemas em produção com redes neurais detectando manipulações de imagem, LLM servindo usuários reais e modelos de ML auditando rede elétrica para achar perda de energia em escala nacional.

PALAVRAS-CHAVE

Data Science · Python · PyTorch · scikit-learn · Hugging Face Transformers · Pandas · NumPy · DuckDB · SQL · ETL/ELT · MLflow · calibração de modelo (ECE) · avaliação fora-de-distribuição (OOD) · séries temporais e foundation models · estatística inferencial (IC, Wilcoxon) · dashboards (Streamlit) · dados públicos brasileiros (IBGE, ONS, INEP) · visão computacional · OCR · Docker · AWS · LGPD e dados sensíveis · mentoria e ensino técnico · liderança técnica de subprojeto · trabalho em time multidisciplinar · metodologias ágeis (Scrum/Kanban)

FORMAÇÃO

- **Mestrado Profissional em Engenharia de Software** — CESAR School, Recife · Out/2025 – defesa prevista para Nov/2026
- **Tecnólogo em Ciência de Dados** — CESAR School, Recife · Jan/2025 – conclusão prevista para Jul/2027
- **Medicina** — FPS / IMIP, Recife · Concluído em 2022

EXPERIÊNCIA

AI Engineer — LetzGrow (School Innovation, CESAR School) · 2026 – atual

Plataforma de carreira assistida por IA: o candidato percorre uma trilha com o Mentor IA e recebe um PDI personalizado. Classificada na edição 2026.2, em dupla.

- **Matching candidato↔oportunidade** com refinamento por Double Opt-In, reduzindo o tempo de pareamento.
- **Avaliação de fairness** do pipeline de recomendação, com relatório versionado.
- **Dados sensíveis:** acesso condicional e trilha de auditoria alinhados à LGPD, sobre PostgreSQL 15 com busca semântica em pgvector.

Lead técnico (dados e visão computacional) — MAPEN (School Innovation, CESAR School) · 2026 – atual

Sistema que localiza perdas de energia comparando energia distribuída e consumida, com redflags por região. Classificado na edição 2026.2. Meu escopo: dados e visão computacional.

- **Camada de dados de escala nacional:** séries horárias de carga do ONS (2000→2026), consumo faturado por UF e malha do IBGE numa base consultável em DuckDB. A diferença entre carga medida e consumo faturado é o próprio sinal de perda.
- **Detecção de anomalia geoespacial-temporal:** modelagem do desvio esperado vs. observado por área, gerando redflags priorizadas por criticidade.
- **Leitura automática de medidores:** fine-tuning de TrOCR-small sobre o dataset UFPR-AMR, comparado a PP-OCRv6-tiny, com tracking em MLflow.

ML Engineer — Veritas (School Innovation, CESAR School) · 2025 – 2026

Detecção de deepfake: visão computacional com Grad-CAM e avaliação de generalização OOD; score forense combinado com explicação por IA generativa.

Monitor — CESAR School · 2025 – 2026

- Monitorias em Programação (C), Estatística (R), Cálculo I, Programação Competitiva e Análise e Visualização de Dados.

Analista de Dados Médicos — J & L Consultoria Hospitalar · 2023 – 2024

Inteligência analítica aplicada à assistência e à gestão hospitalar, cruzando dados clínicos e gerenciais para apoiar a governança.

- **Desfechos clínicos:** medi reinternação, infecção hospitalar e complicações pós-operatórias, apontando falhas e apoiando o ajuste de protocolos.
- **Qualidade e acreditação:** acompanhei os KPIs exigidos pela ONA e pela JCI.
- **Gestão operacional e custos:** analisei ocupação de leitos, produtividade do centro cirúrgico, custos de internação e desvios de tabela, com dashboards em Streamlit para a diretoria.

PRODUÇÕES ACADÊMICAS

1. *Reuso de Treino para Triagem Binária em Imagem Médica Multidomínio* (dissertação de mestrado, CESAR School, 2026): comparação controlada de 4 origens de backbone sobre 5 domínios (MedMNIST), avaliando AUC, calibração (ECE) e fidelidade de explicação por oclusão. O fine-tuning intermediário forense venceu (AUC 0,842 vs. 0,796 do ImageNet) com calibração muito superior (ECE 0,045 vs. 0,219). MLflow e agregação estatística (IC, Wilcoxon) sobre múltiplas seeds.
2. *Generalização assimétrica em detectores de manipulação de imagens: do domínio de treino ao colapso em splicing manual* (SBTI 2026, submetido).
3. *Fine-tuning de decision forests na presença de drift: um blend bayesiano com vocabulário unificado* (SBTI 2026, submetido): biblioteca DeepJungle, validada em 4 benchmarks públicos (Folktables/ACS, Electricity, Covertypes, MNIST rotacionado). github.com/jhlr/deepjungle
4. *EfficientNeXt: um mini-LLM autoregressivo derivado da arquitetura EfficientNet com geração e embedding unificados (GRIT) e steering de decoding sem modelo auxiliar.*
5. *Fiscalização automatizada de fotos de leitura de medidores de energia elétrica: um pipeline de OCR e caracterização do problema de validação de coerência* (SBTI 2026, submetido).

PROJETOS

btc-forecast — foundation models e fine-tuning · github.com/jhlr/BTC-Forecast

Comparação sistemática de 5 foundation models de série temporal zero-shot (Chronos, TimesFM, Moirai, Lag-Llama, TTM) num pipeline reproduzível de fine-tuning, ensemble e backtest direcional, com tracking em MLflow e app Streamlit.

desemprego-educacao-brasil · github.com/jhlr/Desemprego-Brasil

Educação (IDEB/INEP) × desemprego (PNAD/IBGE via API SIDRA): EDA, dashboard Streamlit e relatório em PDF.

COMPETÊNCIAS

Machine learning: PyTorch · scikit-learn · Hugging Face Transformers · OpenCV · transfer learning e fine-tuning (LoRA) · OCR (TrOCR, PaddleOCR) · Grad-CAM e explicabilidade · calibração (ECE) · avaliação OOD · detecção de anomalia · séries temporais e foundation models

Dados: Pandas · NumPy · DuckDB · PostgreSQL e SQL · ETL/ELT · dados geoespaciais (GeoJSON) · dados públicos brasileiros (IBGE, ONS, INEP) · estatística inferencial (IC, Wilcoxon) · dashboards (Streamlit)

MLOps, IA generativa e domínio: MLflow · Docker · AWS · Git · LLMs (OpenAI, Anthropic, Groq, Gemini, Ollama) · RAG e busca vetorial · engenharia de prompt · LGPD e dados sensíveis · modelagem de domínio clínico

Idiomas: Português (nativo) · Inglês (nativo) · Espanhol (básico) · Francês (básico)